

# Delineamento Experimental e Estatística

## Verossimilhança Máxima

# Verossimilhança (*Likelihood*)

- Após um modelo e seus parâmetros serem definidos, e dados coletados, em geral o passo seguinte é estimar seu ajuste (*goodness of fit*)
- Isto é, os valores dos parâmetros do modelo que melhor se ajustam aos dados  
= Estimativa de parâmetros
- Método geral para estimativa de parâmetros: verossimilhança máxima (*maximum likelihood*)
- Quadrados mínimos (*least squares*): caso particular quando os resíduos seguem uma distribuição normal

# Verossimilhança Máxima

- Se a probabilidade de um evento  $x$  depende de parâmetros  $p$  de um modelo, escrevemos

$$P(x | p)$$

- mas quando falamos de verossimilhança

$$L(p | x)$$

- quer dizer, a verossimilhança dos parâmetros considerando o evento  $x$
- Quando estimamos um parâmetro por verossimilhança máxima queremos dizer que procuramos o valor do parâmetro que tenha a maior chance de produzir o evento.

# Verossimilhança Máxima

- Previsões baseando-se em premissas ou modelos muito bem estabelecidos: o objetivo é estimar probabilidades de eventos ocorrerem.
- Mas se estivermos analisando dados, já temos o evento, os dados, e mais de uma hipótese para explicá-los?
- Não há mais uma questão probabilística
- Estamos mais interessados na verossimilhança dos parâmetros do modelo que podem ter resultado os dados observados.
- **Probabilidade**  
Sabendo os parâmetros -> Previsão de resultado
- **Verossimilhança**  
Observação de resultado -> Estimativa de parâmetros

	Viés da moeda favorecendo Cara				
Cara	0,1	0,3	0,5	0,7	0,9
0	0,59	0,17	0,03	0,00	0,00
1	0,33	0,36	0,16	0,03	0,00
2	0,07	0,31	0,31	0,13	0,01
3	0,01	0,13	0,31	0,31	0,07
4	0,00	0,03	0,16	0,36	0,33
5	0,00	0,00	0,03	0,17	0,59



<http://www.rasch.org/rmt/rmt1237.htm>

Suponha que em 5 jogadas da moeda foram obtidas 5 caras. Qual o deve ser o viés da moeda?

- Para estimarmos o viés da moeda, olhamos a probabilidade de obter 5 caras em todas as hipóteses. A hipótese onde esta frequência é a mais provável fornece uma estimativa do viés.
- No caso, 0,9 é a estimativa mais próxima do viés.
- O somatório dos valores de uma coluna é sempre 1,0. São as probabilidades dos resultados em cada hipótese, cada coluna uma hipótese.
- Como o somatório dos valores de uma linha é sempre diferente de 1, foi necessário diferenciar estes valores de probabilidades, adotando-se o termo verossimilhança (*likelihood*).

# Estimativa por verossimilhança

$n = 100$  (total de lançamentos da moeda)

$h = 56$  (total de caras)

OBTIVEMOS 56 CARAS E 44 CORÔAS. É UMA MOEDA “JUSTA”?

Precisamos de um modelo estatístico para descrever o fenômeno!

Variável aleatória binomial

$$P(X) = \frac{n!}{X!(n-X)!}$$

# Estimativa por verossimilhança

Mas no caso temos  $X = 56$  e  $n = 100$ , falta o valor de  $p$ , que estamos estimando.

$$P(56) = \frac{100!}{56! (100 - 56)!}$$

$$P(56) = \frac{100!}{56! (44)!}$$

$$P(56) = (4,94 \times 10^{-15})$$



# Estimativa por verossimilhança

Quando temos uma função do parâmetro  
(desconhecido),

mas as observações são fixas,

temos uma função de verossimilhança,

(não mais de densidade de probabilidade)

# Estimativa por verossimilhança

$n = 100$  (total de lançamentos da moeda)

$h = 56$  (total de caras)

OBTIVEMOS 56 CARAS E 44 CORÔAS. É UMA MOEDA “JUSTA”?

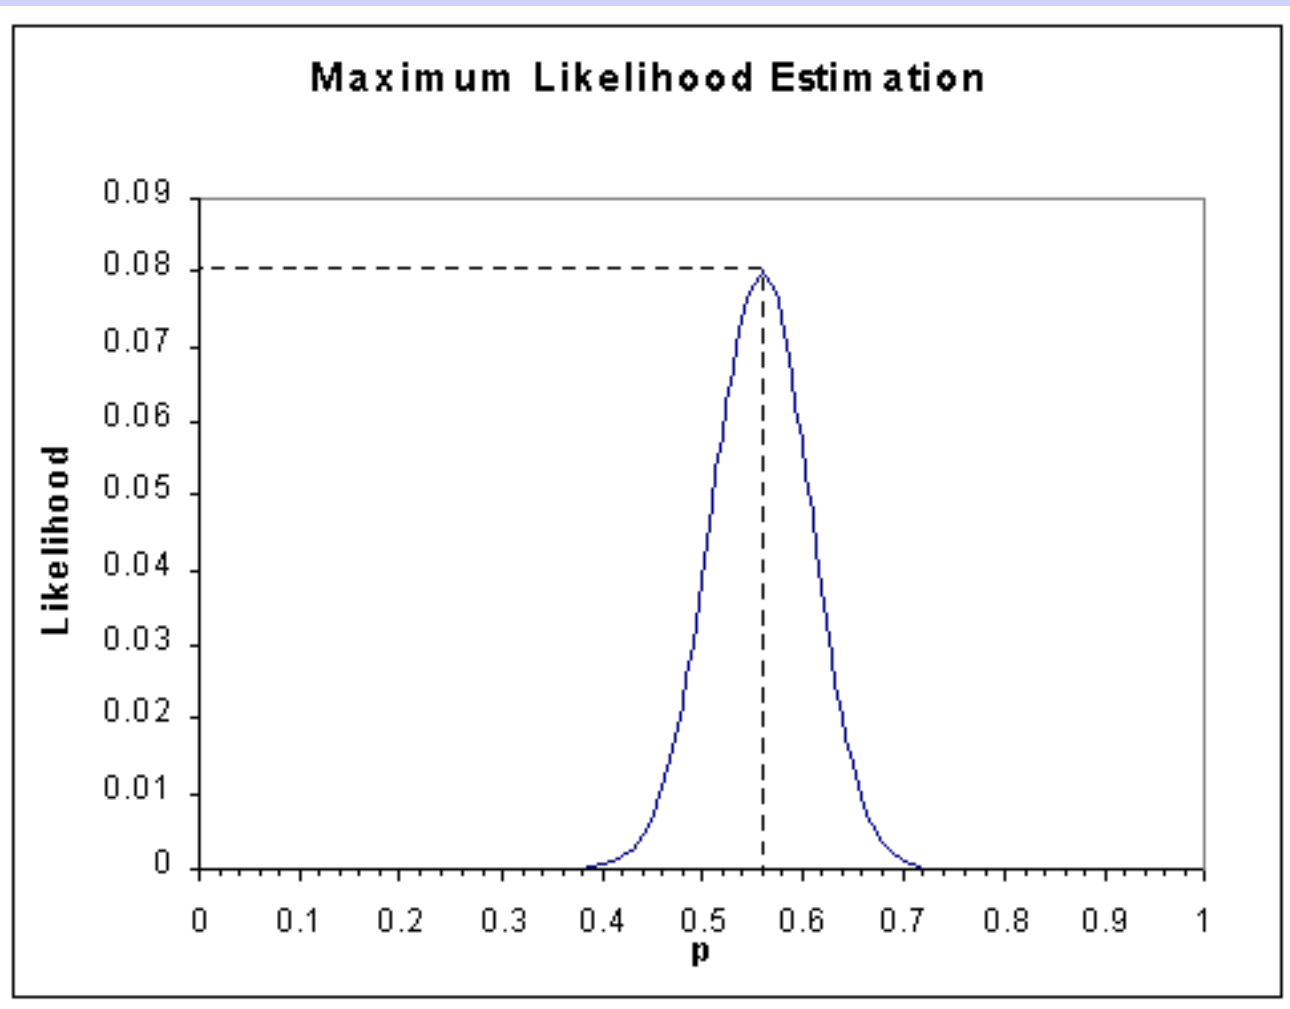
Se  $p = 0,5$

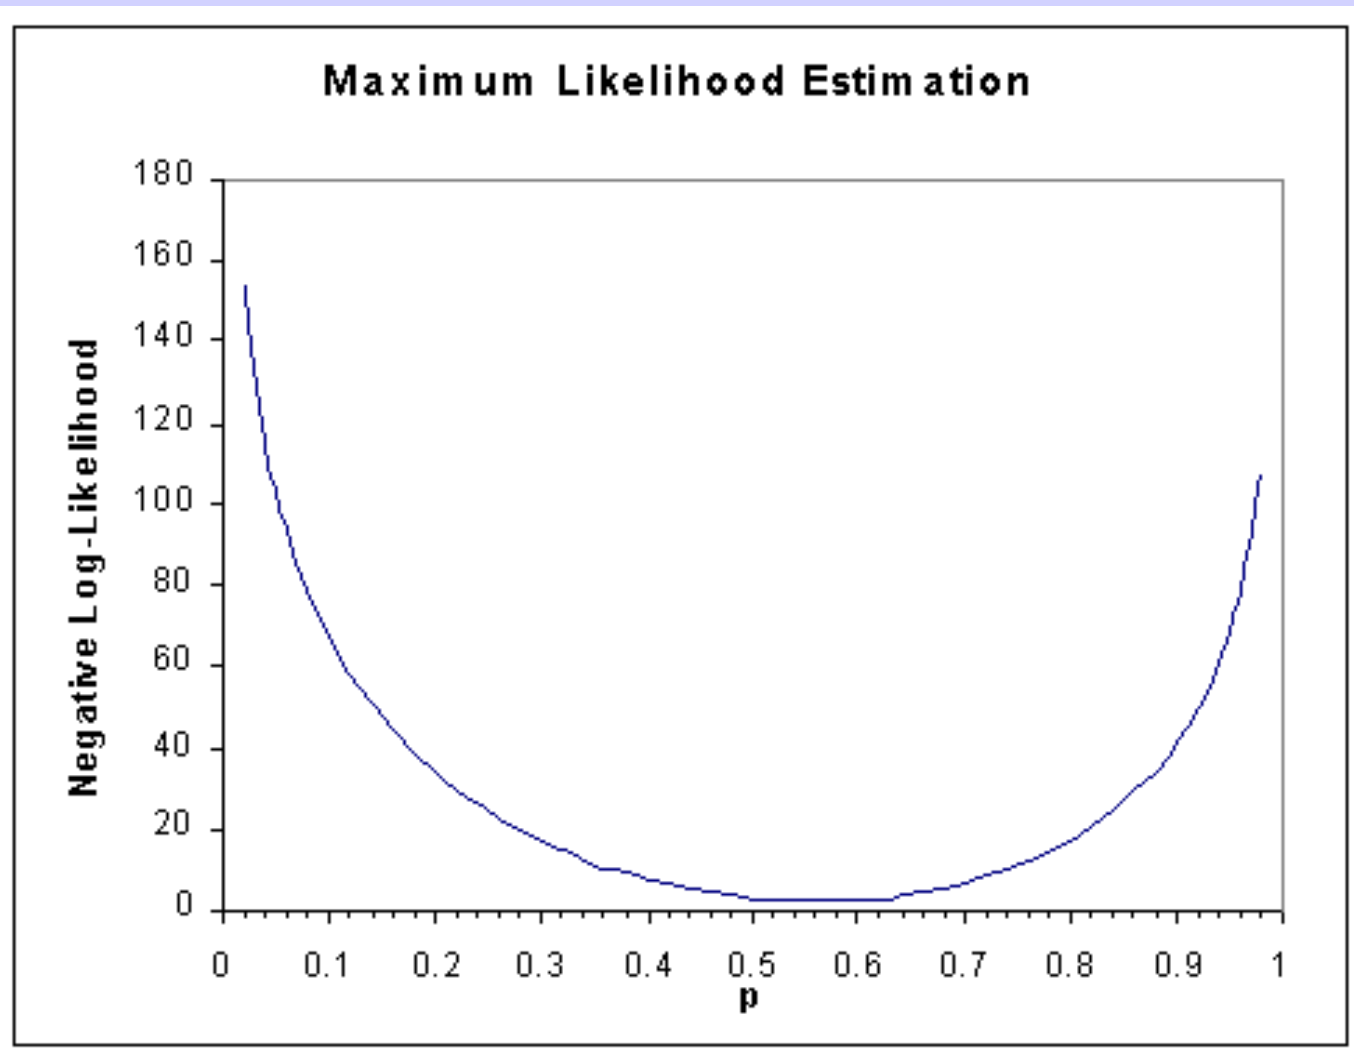
$$L(p = 0.5 | data) = \frac{100!}{56!44!} 0.5^{56} 0.5^{44} = 0.0389$$

$$L(p = 0.52 | data) = \frac{100!}{56!44!} 0.52^{56} 0.48^{44} = 0.0581$$

p	L
0.48	0.0222
0.52	0.0581
0.56	0.0801
0.60	0.0576

p	L
0.50	0.0389
0.54	0.0739
0.58	0.0738
0.62	0.0378





$$\mathcal{L}\{\mu|X_n\} = \prod_{i=1}^n \frac{e^{-\mu} \mu^{x_i}}{x_i!} = e^{-\mu} \prod_{i=1}^n \frac{\mu^{x_i}}{x_i!}$$

PARCELA	NO. DE PLÂT
(i)	(X=)
1	24
2	27

$$L\{\mu|X_n\} = n\mu - \log(\mu) \sum_{i=1}^n x_i + \sum_{i=1}^n \log(x_i!)$$

$$L\{\mu|X_n\} = n\mu - \log(\mu) k_1 + k_2$$



PARCELA NO. DE PLÂNT

(i) (X=xi)



1 24

2 27

~ ~







$$Y = \beta_0 + \beta_1 x + u$$

$$u \sim N(0, \sigma^2) \quad P(u_i) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{u - \bar{u}}{\sigma}\right)^2}$$

$$L(\text{amostra}) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{u_1}{\sigma}\right)^2} \dots$$


$$= \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{\sum_{i=1}^n u_i}{\sigma}\right)^2} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{\sum (u_i - \bar{u})}{\sigma}\right)^2}$$

$$\log \left( \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2} \left( \sum_{i=1}^n u_i / \sigma \right)^2} \right) = \frac{1}{(2\pi\sigma^2)^{1/2}} e^{-\frac{1}{2} \left( \sum_{i=1}^n u_i / \sigma \right)^2}$$

$$(2\pi\sigma^2)^{-1/2} e^{-\frac{1}{2} \left( \sum_{i=1}^n u_i / \sigma \right)^2}$$


- $\text{Log L} = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2} \quad \text{—}$

- $\text{Log } L = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2} \cdot \quad -$



- A estimativa de  $\sigma^2$  que maximiza sua verossimilhança é a Soma dos Quadrados dos Resíduos por  $n = \text{RSS}/n$
- Que difere da estimativa de  $\sigma^2$  pelos quadrados mínimos:  $\text{RSS}/(n-k)$  (devido à correção do viés para amostras pequenas)
- Este viés não é importante para estimativas de VM, mas RSS é dividido por valores diferentes!

- $$\text{Log } L = -\frac{n}{2} \ln \left( \frac{2\pi \text{RSS}}{n} \right) - \frac{1}{2} \frac{\text{RSS}}{\text{RSS}} \quad - \quad \text{_____}$$



# Lei ou princípio da verossimilhança

- Duas hipóteses, A e B
- Resultado  $x$  podem ocorrer segundo estas duas hipóteses e uma variável aleatória  $X$
- $P(A) = x > P(B) = x$
- Razão de verossimilhança:

mede a **força de evidência** a favor de uma hipótese